AI VIET NAM – AI COURSE 2025

Step-by-Step: Random Forest

Dương Trường Bình Dương Đình Thắng Đinh Quang Vinh

I. Dẫn nhập

Trong quản trị và đầu tư, có một nguyên tắc nổi tiếng là *"Đừng bao giờ bỏ tất cả trứng vào cùng một giỏ"*. Triết lý này khuyên chúng ta nên đa dạng hóa danh mục đầu tư để giảm thiểu rủi ro; nếu một khoản đầu tư thất bại, các khoản khác vẫn có thể bù lại. Một ý tưởng tương tự cũng xuất hiện trong đời sống khi chúng ta cần đưa ra một quyết định quan trọng: thay vì chỉ tin vào ý kiến của một chuyên gia duy nhất, ta thường tham khảo ý kiến từ một hội đồng gồm nhiều chuyên gia độc lập. Quyết định cuối cùng được đưa ra dựa trên sự đồng thuận của số đông, và thường sẽ đáng tin cậy và chính xác hơn nhiều.

Hình 1: Thuật toán Random Forest là một tập hợp của nhiều Decision Tree riêng lẻ.

Và cũng chính triết lý về "wisdom of the crowd" (tạm dịch: trí tuệ tập thể)[1] là nguyên lý cốt lõi làm nên sức mạnh của một trong những thuật toán học máy hiệu quả nhất: **Random Forest** (tạm dịch: Rừng Ngẫu nhiên). Được phát triển bởi Leo Breiman và Adele Cutler vào năm 2001[2], Random Forest là một ví dụ điển hình của phương pháp học máy *ensemble learning*, nơi sức mạnh của nhiều mô hình được kết hợp lại để tạo ra một kết quả dự đoán vượt trội.
Trong bài viết này, chúng ta sẽ cùng nhau tìm hiểu sâu hơn về thuật toán Random Forest. Chúng ta sẽ bắt đầu bằng việc định nghĩa bài toán và các khái niệm nền tảng, sau đó đi sâu vào cơ chế hoạt động chi tiết, và cuối cùng là áp dụng thuật toán vào một bài toán thực tế.

[1] Khái niệm "The Wisdom of Crowds" được phổ biến rộng rãi bởi James Surowiecki trong cuốn sách cùng tên xuất bản năm 2004.

[2] Leo Breiman, "Random Forests," *Machine Learning*, 45(1), 5–32, 2001.

Mục lục

I. Dẫn nhập **1**

II. Thuật toán Random Forest **3**

II.1. Giới thiệu 3

II.2. Phát biểu bài toán 4

II.3. Ôn tập nhanh: Xây dựng một Cây Quyết định 4

II.4. Cách hoạt động 6

III. Thực hành **9**

III.1. Mô tả bài toán 9

III.2. Lời giải 10

IV. Câu hỏi trắc nghiệm **14**

Phụ lục **16**

II. Thuật toán Random Forest

II.1. Giới thiệu

Về cốt lõi, Random Forest là một tập hợp của nhiều mô hình đơn giản hơn gọi là **Decision Tree** (tạm dịch: Cây quyết định). Mỗi cây quyết định giống như một chuyên gia riêng lẻ, đưa ra dự đoán dựa trên một loạt các câu hỏi "nếu-thì". Tuy nhiên, một cây quyết định đơn lẻ, dù hoạt động rất tốt trên dữ liệu huấn luyện, lại cực kỳ nhạy cảm với những thay đổi nhỏ trong dữ liệu và dễ dàng bị *overfitting* (tạm dịch: quá khớp). Random Forest giải quyết vấn đề này bằng cách xây dựng nhiều cây quyết định đa dạng và tương đối độc lập với nhau, sau đó tổng hợp dự đoán của chúng thông qua một cơ chế "bỏ phiếu".

Trước khi đi sâu vào cơ chế hoạt động, chúng ta sẽ lần lượt đi qua các nội dung nền tảng: làm quen với các ký hiệu toán học, định nghĩa bài toán một cách chính thức, và ôn tập nhanh lại kiến thức về thuật toán Decision Tree.

Bảng Ký hiệu Toán học

Ký hiệu	Ý nghĩa
B	Siêu tham số, là tổng số cây quyết định trong rừng.
N	Tổng số điểm dữ liệu trong tập huấn luyện gốc.
n	Tổng số chiều (đặc trưng) của dữ liệu.
m	Siêu tham số, là số lượng đặc trưng được chọn ngẫu nhiên tại mỗi nút để tìm cách phân chia tốt nhất ($m < n$).
$\mathcal{D}$	Tập dữ liệu huấn luyện gốc, $\mathcal{D} = \{(\mathbf{p}_1, y_1), \ldots, (\mathbf{p}_N, y_N)\}$.
$\mathcal{D}_b$	Mẫu bootstrap thứ b, được tạo bằng cách lấy mẫu có hoàn lại N lần từ $\mathcal{D}$.
T_b	Cây quyết định thứ b được huấn luyện trên mẫu bootstrap $\mathcal{D}_b$.
S	Một tập (hoặc nút) dữ liệu cần phân tách.
p_c	Tỷ lệ các mẫu thuộc lớp c trong tập S.
$H(S)$	Entropy của tập S.
$G(S)$	Gini Impurity của tập S.
$\mathbf{p}_{new}$	Điểm dữ liệu mới cần được dự đoán.
$\hat{y}_b(\mathbf{p}_{new})$	Dự đoán của cây thứ b cho điểm dữ liệu mới $\mathbf{p}_{new}$.
$\hat{y}_{RF}(\mathbf{p}_{new})$	Dự đoán cuối cùng của Random Forest cho điểm dữ liệu mới.

II.2. Phát biểu bài toán

Trong một bài toán học máy có giám sát, chúng ta được cung cấp một tập dữ liệu huấn luyện $\mathcal{D} = \{(\mathbf{p}_1, y_1), \ldots, (\mathbf{p}_N, y_N)\}$.

- Mỗi mẫu dữ liệu $\mathbf{p}_i$ là một vector đặc trưng n chiều, tức là $\mathbf{p}_i \in \mathbb{R}^n$.
- Nhãn tương ứng y_i có thể là:
  - Một giá trị rời rạc từ một tập hữu hạn các lớp $\{c_1, c_2, \ldots, c_K\}$ (bài toán **phân loại**).
  - Một giá trị thực, $y_i \in \mathbb{R}$ (bài toán **hồi quy**).

Mục tiêu của chúng ta là học một hàm (mô hình) $f : \mathbb{R}^n \to \mathcal{Y}$ từ dữ liệu huấn luyện, sao cho hàm này có thể dự đoán chính xác nhãn y cho một vector đặc trưng $\mathbf{p}$ mới chưa từng thấy. Không gian nhãn $\mathcal{Y}$ là tập các lớp hoặc tập số thực tùy vào bài toán.

Trong bối cảnh của bài viết này, hàm f chính là mô hình Random Forest mà chúng ta cần xây dựng:

$$\hat{y}_{new} = f(\mathbf{p}_{new}) = \text{RandomForest}(\mathbf{p}_{new})$$

II.3. Ôn tập nhanh: Xây dựng một Cây Quyết định

Mục tiêu: Xây dựng một cấu trúc dạng cây để phân loại dữ liệu bằng cách liên tục hỏi các câu hỏi về đặc trưng. Mục đích cuối cùng là tạo ra các nút lá càng "thuần khiết" càng tốt, tức là chỉ chứa các mẫu thuộc về một lớp duy nhất.

Tiêu chí phân tách: Để quyết định thuộc tính nào và ngưỡng nào là tốt nhất để phân tách tại một nút, thuật toán đo lường mức độ impurity (tạm dịch: không thuần khiết) của dữ liệu. Một lần phân tách tốt sẽ làm giảm impurity nhiều nhất.

1. Entropy & Information Gain

- **Entropy** $H(S)$ đo lường mức độ hỗn loạn của một tập dữ liệu S:

$$H(S) = -\sum_c p_c \log_2(p_c),$$

- **Information Gain** $\text{IG}(S, A)$ đo lường mức độ giảm Entropy khi phân tách tập S theo thuộc tính A.

$$\text{IG}(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v).$$

2. Gini Impurity & Gini Gain

- **Gini Impurity** $G(S)$ đo xác suất phân loại sai một mẫu nếu gán nhãn ngẫu nhiên:

$$G(S) = 1 - \sum_c p_c^2,$$

- **Gini Gain** $\text{GG}(S, A)$ đo lường mức độ giảm Gini Impurity khi phân tách tập S theo thuộc tính A.

$$\text{GG}(S, A) = G(S) - \sum_v \frac{|S_v|}{|S|} G(S_v).$$

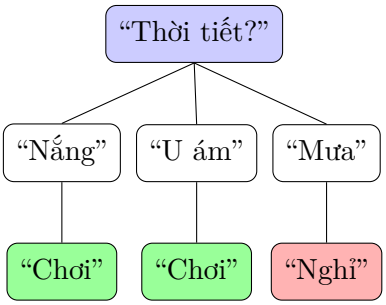

Hình 2: Cây quyết định minh họa.

Quy trình xây dựng cây (tóm tắt):

1. **Bắt đầu từ gốc.** Toàn bộ dữ liệu huấn luyện được đặt vào một nút duy nhất, gọi là nút gốc.

2. **Tìm câu hỏi phân tách tốt nhất.** Thuật toán lặp qua tất cả đặc trưng và các ngưỡng chia khả dĩ để tìm tiêu chí phân tách giúp giảm độ impurity nhiều nhất.

3. **Phân tách dữ liệu.** Dữ liệu tại nút hiện tại được chia thành các nút con mới dựa trên câu trả lời cho câu hỏi tốt nhất đã chọn.

4. **Lặp lại một cách đệ quy.** Quy trình từ Bước 2 được lặp cho mỗi nút con. Quá trình này sẽ dừng lại tại một nhánh khi nó trở nên thuần khiết hoặc đạt điều kiện dừng khác (ví dụ: độ sâu tối đa của cây).

II.4. Cách hoạt động

Quá trình hoạt động của Random Forest có thể được chia thành 3 bước như trong Hình 3.

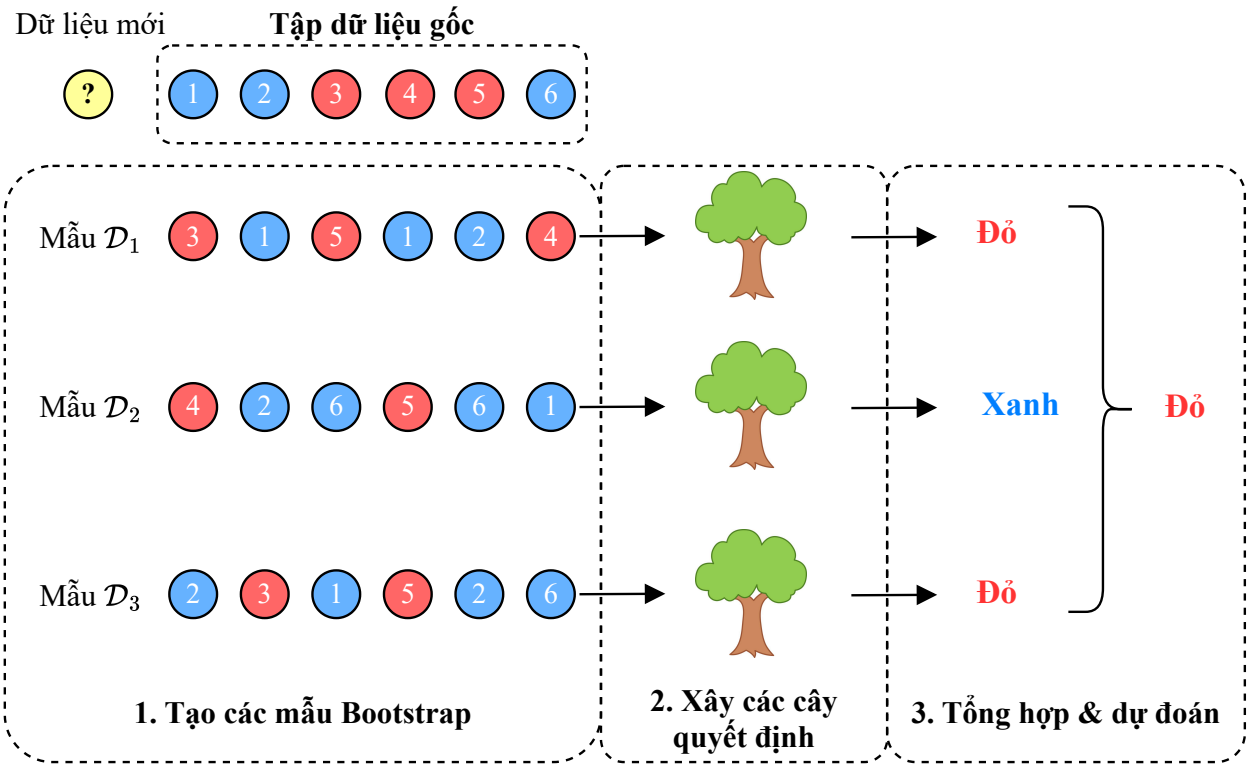

Hình 3: Tổng quan các bước của thuật toán Random Forest.

Bước 1: Tạo các mẫu Bootstrap

Cốt lõi để tạo ra một "rừng" hiệu quả là sự đa dạng của các cây. Nếu tất cả các cây đều giống hệt nhau, chúng sẽ mắc phải những lỗi giống nhau, và việc kết hợp chúng lại không mang lại lợi ích gì. Yếu tố ngẫu nhiên đầu tiên đến từ việc cho mỗi cây "nhìn thấy" một phiên bản hơi khác của dữ liệu gốc.

Bagging

Ý tưởng: Thay vì huấn luyện mọi cây trên cùng một bộ dữ liệu, ta tạo ra nhiều bộ dữ liệu con bằng cách lấy mẫu ngẫu nhiên **có hoàn lại** từ dữ liệu gốc.
Mục đích: Mỗi cây sẽ học được những quy luật hơi khác nhau, trở thành một "chuyên gia" với góc nhìn riêng, từ đó tạo ra một khu rừng đa dạng.

Kỹ thuật này được gọi là **Bagging** (**B**ootstrap **Agg**regat**ing**), bao gồm:

1. Từ tập huấn luyện gốc $\mathcal{D}$ có N điểm dữ liệu, ta tạo ra B tập dữ liệu mới $\mathcal{D}_1, \ldots, \mathcal{D}_B$.
2. Mỗi tập $\mathcal{D}_b$ (gọi là **mẫu bootstrap**) được tạo bằng cách lấy mẫu **có hoàn lại** N lần từ tập $\mathcal{D}$.

Việc lấy mẫu có hoàn lại có nghĩa là một điểm dữ liệu có thể được chọn nhiều lần trong cùng một mẫu bootstrap. Kết quả là, trung bình mỗi mẫu bootstrap sẽ chứa khoảng 63.2%[3] các điểm dữ liệu duy nhất từ tập gốc. Những điểm không được chọn được gọi là **Out-of-Bag (OOB)** và rất hữu ích để đánh giá mô hình sau này.

Bước 2: Xây dựng các Cây Quyết định độc lập

Với mỗi mẫu bootstrap đã tạo, ta sẽ xây dựng một cây quyết định hoàn chỉnh. Yếu tố ngẫu nhiên thứ hai, và cũng là cải tiến độc đáo của Random Forest so với Bagging thông thường, nằm ở cách mỗi cây này được xây dựng.

Feature Randomness

Ý tưởng: Tại mỗi bước phân tách của cây, thay vì xem xét tất cả các đặc trưng để tìm ra cách chia tốt nhất, thuật toán chỉ xem xét một **tập con ngẫu nhiên** các đặc trưng.
Mục đích: Ngăn chặn việc một vài đặc trưng quá mạnh chiếm ưu thế trong tất cả các cây. Điều này buộc các cây phải khám phá các đặc trưng khác, làm chúng trở nên khác biệt và ít tương quan với nhau hơn.

Cụ thể, với mỗi mẫu bootstrap $\mathcal{D}_b$, ta xây dựng một cây quyết định T_b. Quá trình xây dựng cây này có hai điểm đặc biệt:

- **Lựa chọn đặc trưng ngẫu nhiên:** Tại mỗi nút, khi tìm cách phân chia tốt nhất, thuật toán chỉ chọn ngẫu nhiên m đặc trưng (với $m < n$) và tìm điểm chia tốt nhất chỉ trong số m đặc trưng này.
- **Phát triển cây tối đa:** Các cây thường được phát triển đến độ sâu tối đa mà không cần pruning (tạm dịch: cắt tỉa). Hiện tượng overfitting của từng cây riêng lẻ sẽ được giảm thiểu nhờ quá trình tổng hợp kết quả ở bước 3.

Chọn siêu tham số m như thế nào?

Việc chọn m là một quyết định quan trọng. Các giá trị thường được đề xuất[a] là:

- Cho bài toán **phân loại**: $m \approx \sqrt{n}$.
- Cho bài toán **hồi quy**: $m \approx n/3$.

[a] Leo Breiman, "Random Forests," *Machine Learning*, 45(1), 5–32, 2001.

Bước 3: Tổng hợp kết quả để đưa ra dự đoán

Sau khi rừng đã được xây dựng, một điểm dữ liệu mới $\mathbf{p}_{new}$ sẽ được đưa qua tất cả các cây để thu về các dự đoán riêng lẻ. Các dự đoán này sau đó được tổng hợp lại để đưa ra kết quả cuối cùng, tùy thuộc vào loại bài toán:

[3] Với N là tổng số mẫu, xác suất một mẫu cụ thể không được chọn trong một lần lấy là $(1 - 1/N)$. Sau N lần lấy, xác suất nó không bao giờ được chọn là $(1 - 1/N)^N$. Khi N lớn, biểu thức này tiến tới $1/e \approx 0.368$. Do đó, tỷ lệ các điểm dữ liệu duy nhất có trong mẫu là $1 - 1/e \approx 0.632$.

Đối với bài toán Phân loại - Lấy phiếu theo đa số (Majority Voting): Nhãn dự đoán cuối cùng là nhãn được nhiều cây "bỏ phiếu" nhất.

$$\hat{y}_{RF}(\mathbf{p}_{new}) = \underset{c}{\operatorname{argmax}} \sum_{b=1}^{B} I(\hat{y}_b(\mathbf{p}_{new}) = c)$$

Ví dụ: Giả sử một khu rừng có $B = 5$ cây cần phân loại một email là "Spam" hay "Không Spam". Kết quả dự đoán của 5 cây lần lượt là:

- Cây 1: "Spam".
- Cây 2: "Không Spam".
- Cây 3: "Spam".
- Cây 4: "Spam".
- Cây 5: "Không Spam".

Tổng kết phiếu bầu: 3 phiếu cho "Spam" và 2 phiếu cho "Không Spam". Do đó, dự đoán cuối cùng của mô hình là "Spam".

Đối với bài toán Hồi quy - Lấy giá trị trung bình (Averaging): Giá trị dự đoán cuối cùng là trung bình cộng của tất cả các dự đoán từ các cây.

$$\hat{y}_{RF}(\mathbf{p}_{new}) = \frac{1}{B} \sum_{b=1}^{B} \hat{y}_b(\mathbf{p}_{new})$$

Ví dụ: Một khu rừng có $B = 4$ cây được dùng để dự đoán giá của một căn nhà (đơn vị: tỷ VNĐ). Kết quả dự đoán của 4 cây lần lượt là:

- Cây 1: 2.1
- Cây 2: 2.3
- Cây 3: 2.0
- Cây 4: 2.2

Dự đoán cuối cùng là trung bình cộng của các kết quả trên:

$$\hat{y}_{RF} = \frac{2.1 + 2.3 + 2.0 + 2.2}{4} = \frac{8.6}{4} = 2.15$$

Vậy, mô hình dự đoán giá nhà là 2.15 tỷ VNĐ.

III. Thực hành

III.1. Mô tả bài toán

Yêu cầu: Dựa trên một tập dữ liệu nhỏ về các đặc điểm cá nhân, hãy xây dựng một mô hình Random Forest đơn giản để dự đoán một người có bị cháy nắng hay không (**Kết quả**).

Thiết lập bài toán

- **Bài toán:** Phân loại nhị phân.
- **Mục tiêu:** Dự đoán nhãn "Cháy nắng" hoặc "Không cháy nắng".
- **Siêu tham số mô hình:** Ta sẽ xây dựng một "khu rừng" với $B = 3$ cây quyết định. Tại mỗi nút, ta sẽ chọn ngẫu nhiên $m = \sqrt{4} = 2$ đặc trưng để tìm cách phân chia tốt nhất.

Dữ liệu Huấn luyện ($N = 6$):

Bảng 1: Dữ liệu huấn luyện để xây dựng mô hình.

ID	Màu tóc	Chiều cao	Cân nặng	Dùng kem	Kết quả
1	Đen	Trung bình	Nhẹ	Không	Cháy nắng
2	Đen	Cao	Trung bình	Có	Không
3	Râm	Thấp	Trung bình	Có	Không
4	Nâu	Thấp	Trung bình	Không	Cháy nắng
5	Nâu	Trung bình	Nặng	Không	Cháy nắng
6	Râm	Trung bình	Nặng	Có	Không

Dữ liệu Kiểm tra (1 mẫu):

Bảng 2: Mẫu dữ liệu mới cần dự đoán.

ID	Màu tóc	Chiều cao	Cân nặng	Dùng kem	Kết quả
7	Nâu	Trung bình	Nhẹ	Có	**?**

III.2. Lời giải

Chúng ta sẽ thực hiện tuần tự 3 bước chính của thuật toán với $B = 3$ cây. Ta sử dụng độ đo **Gini impurity** để chọn cách phân tách.

Lưu ý: Vì các bước xây dựng một cây quyết định đã được trình bày chi tiết ở bài trước, phần này sẽ tóm tắt các bước tính toán để tập trung vào quy trình tổng thể của Random Forest.

Bước 1: Tạo các mẫu Bootstrap

Mẫu $\mathcal{D}_1$ (giả định): Lấy ngẫu nhiên 6 mẫu có hoàn lại, ta được tập ID **{1, 5, 2, 6, 5, 3}**.

Bảng 3: Dữ liệu trong mẫu bootstrap $\mathcal{D}_1$.

ID	Màu tóc	Chiều cao	Cân nặng	Dùng kem	Kết quả
1	Đen	Trung bình	Nhẹ	Không	Cháy nắng
5	Nâu	Trung bình	Nặng	Không	Cháy nắng
2	Đen	Cao	Trung bình	Có	Không
6	Râm	Trung bình	Nặng	Có	Không
5	Nâu	Trung bình	Nặng	Không	Cháy nắng
3	Râm	Thấp	Trung bình	Có	Không

Mẫu $\mathcal{D}_2$ (giả định): Lấy ngẫu nhiên 6 mẫu khác, ta được tập ID **{4, 1, 6, 2, 4, 2}**.

Bảng 4: Dữ liệu trong mẫu bootstrap $\mathcal{D}_2$.

ID	Màu tóc	Chiều cao	Cân nặng	Dùng kem	Kết quả
4	Nâu	Thấp	Trung bình	Không	Cháy nắng
1	Đen	Trung bình	Nhẹ	Không	Cháy nắng
6	Râm	Trung bình	Nặng	Có	Không
2	Đen	Cao	Trung bình	Có	Không
4	Nâu	Thấp	Trung bình	Không	Cháy nắng
2	Đen	Cao	Trung bình	Có	Không

Mẫu $\mathcal{D}_3$ (giả định): Lấy ngẫu nhiên 6 mẫu khác, ta được tập ID **{3, 4, 1, 4, 5, 3}**.

Bảng 5: Dữ liệu trong mẫu bootstrap $\mathcal{D}_3$.

ID	Màu tóc	Chiều cao	Cân nặng	Dùng kem	Kết quả
3	Râm	Thấp	Trung bình	Có	Không
4	Nâu	Thấp	Trung bình	Không	Cháy nắng
1	Đen	Trung bình	Nhẹ	Không	Cháy nắng
4	Nâu	Thấp	Trung bình	Không	Cháy nắng
5	Nâu	Trung bình	Nặng	Không	Cháy nắng
3	Râm	Thấp	Trung bình	Có	Không

Bước 2: Xây dựng các Cây Quyết định

Xây dựng Cây 1 (T_1) trên mẫu $\mathcal{D}_1$

- **Nút gốc:** Mẫu $\mathcal{D}_1$ có 3 "Cháy nắng" và 3 "Không", do đó $G_{\text{gốc}} = 0.5$.
- **Phân chia:**
  - Chọn ngẫu nhiên 2 đặc trưng: **{Màu tóc, Dùng kem}**.
  - **So sánh Gini Gain:**
    - Chia theo "Dùng kem" tạo 2 nhánh thuần khiết. Gini sau chia = 0 → **Gini Gain = 0.5**.
    - Chia theo "Màu tóc" tạo 3 nhánh. Gini sau chia ≈ 0.167 → **Gini Gain = 0.333**.
  - **Kết luận:** Chọn chia theo "Dùng kem". Vì các nút con đã thuần khiết, cây dừng lại.

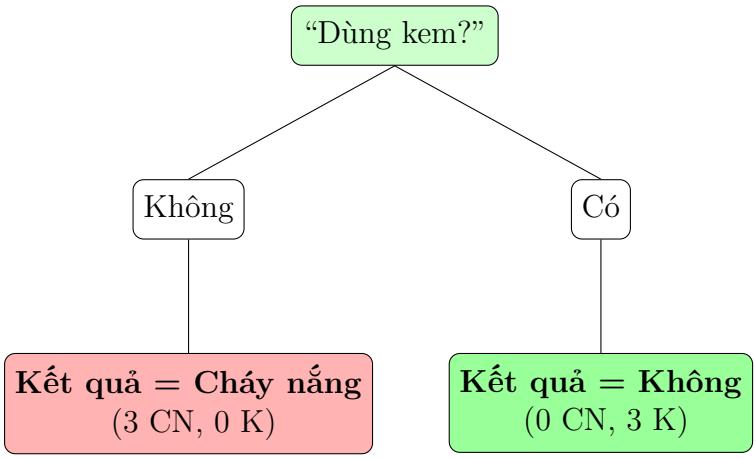

Hình 4: Sơ đồ cây quyết định T_1.

Xây dựng Cây 2 (T_2) trên mẫu $\mathcal{D}_2$

- **Nút gốc:** Mẫu $\mathcal{D}_2$ có 3 "Cháy nắng" và 3 "Không", $G_{\text{gốc}} = 0.5$.
- **Phân chia (lần 1):**
  - Chọn ngẫu nhiên 2 đặc trưng: **{Chiều cao, Cân nặng}**.
  - **So sánh Gini Gain:**
    - Chia theo "Chiều cao" tạo 3 nhánh. Gini sau chia $\approx$ 0.167 $\rightarrow$ **Gini Gain = 0.333**.
    - Chia theo "Cân nặng" tạo 3 nhánh. Gini sau chia $\approx$ 0.333 $\rightarrow$ **Gini Gain = 0.167**.
  - **Kết luận:** Ta chọn chia theo "Chiều cao" vì có Gini Gain cao hơn.
- **Phân chia (lần 2) cho nút "Trung bình":**
  - Nhánh "Trung bình" (gồm hai mẫu {1, 6}) chưa thuần khiết, có 1 "Cháy nắng" và 1 "Không" ($G = 0.5$).
  - Chọn ngẫu nhiên 2 đặc trưng mới: **{Màu tóc, Dùng kem}**.
  - Chia theo "Dùng kem" sẽ tách {1} (nhánh "Không") và {6} (nhánh "Có"). Cách chia này tạo ra 2 nút con thuần khiết, do đó Gini của chúng đều bằng 0 và Gini Gain được tính bằng 0.5. Đây là mức giảm impurity tối đa, nên ta chọn cách chia này.

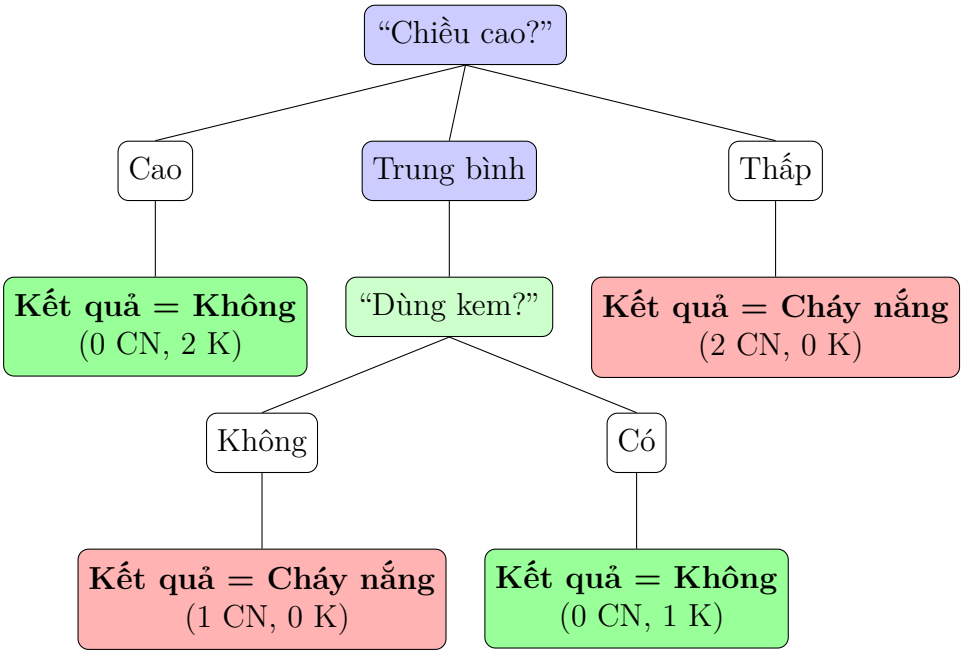

Hình 5: Sơ đồ cây quyết định T_2.

Xây dựng Cây 3 (T_3) trên mẫu $\mathcal{D}_3$

- **Nút gốc:** Mẫu $\mathcal{D}_3$ có 4 "Cháy nắng" và 2 "Không", do đó $G_{\text{gốc}} \approx 0.444$.
- **Phân chia:** Chọn ngẫu nhiên 2 đặc trưng **{Cân nặng, Dùng kem}**. Chia theo "Dùng kem" cho Gini Gain cao nhất (0.444).
- **Kết luận:** Cây dừng lại vì các nút con đã thuần khiết.

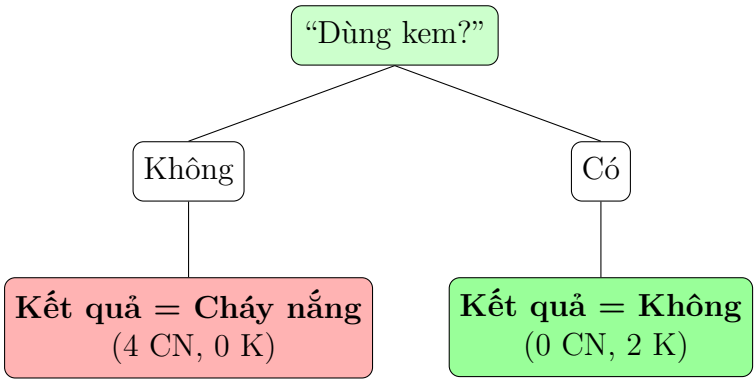

Hình 6: Sơ đồ cây quyết định T_3.

Bước 3: Dự đoán và Tổng hợp kết quả

Bây giờ, ta đưa mẫu kiểm tra **ID=7 (Nâu, Trung bình, Nhẹ, Có)** vào cả ba cây.
Dự đoán của từng cây:

- **Cây T_1:** Mẫu 7 có "Dùng kem = Có" $\rightarrow$ Dự đoán là **Không**.
- **Cây T_2:** Mẫu 7 có "Chiều cao = Trung bình" và "Dùng kem = Có" $\rightarrow$ Dự đoán là **Không**.
- **Cây T_3:** Mẫu 7 có "Dùng kem = Có" $\rightarrow$ Dự đoán là **Không**.

Tổng hợp kết quả (Majority Voting)

- Phiếu từ T_1: **Không**.
- Phiếu từ T_2: **Không**.
- Phiếu từ T_3: **Không**.

Kết luận cuối cùng

Mô hình Random Forest dự đoán **Kết quả** cho mẫu ID=7 là **Không cháy nắng**.

IV. Câu hỏi trắc nghiệm

1. Đâu là hai cơ chế chính tạo ra sự ngẫu nhiên trong thuật toán Random Forest?
   (a) Bagging và Pruning (Cắt tỉa).
   (b) Bagging và Feature Randomness (Lựa chọn đặc trưng ngẫu nhiên).
   (c) Gini Impurity và Entropy.
   (d) Feature Scaling và Out-of-Bag (OOB) Error.
2. Nhược điểm chính của một cây quyết định đơn lẻ mà Random Forest khắc phục được là gì?
   (a) Độ chệch (bias) cao.
   (b) Phương sai (variance) cao và dễ bị overfitting.
   (c) Tốc độ dự đoán chậm.
   (d) Không xử lý được dữ liệu dạng phân loại (categorical).
3. Tại sao các cây quyết định trong Random Forest thường được phát triển đến độ sâu tối đa mà không cần cắt tỉa?
   (a) Để tăng tốc độ huấn luyện cho mỗi cây.
   (b) Vì việc cắt tỉa sẽ làm giảm độ chệch (bias) của mỗi cây.
   (c) Vì hiện tượng overfitting của từng cây sẽ được giảm thiểu bởi quá trình tổng hợp kết quả (voting/averaging).
   (d) Để đảm bảo tất cả các cây trong rừng đều có cấu trúc giống hệt nhau.
4. Một Random Forest gồm 5 cây được huấn luyện cho bài toán phân loại 3 lớp (A, B, C). Với một điểm dữ liệu mới, dự đoán của 5 cây lần lượt là: [A, C, B, C, C]. Kết quả dự đoán cuối cùng của mô hình là gì?
   (a) A.
   (b) B.
   (c) C.
   (d) Không xác định được do hòa phiếu.
5. Theo các giá trị đề xuất trong bài, nếu một bài toán hồi quy có 12 đặc trưng ($n = 12$), siêu tham số m (số lượng đặc trưng xét tại mỗi nút) nên được chọn là bao nhiêu?
   (a) $m = 3$.
   (b) $m = 4$.
   (c) $m = 6$.
   (d) $m = 12$.
6. Điều gì xảy ra nếu ta tăng siêu tham số m đến giá trị tối đa là $m = n$?

(a) Độ tương quan giữa các cây trong rừng sẽ tăng lên.

(b) Độ tương quan giữa các cây trong rừng sẽ giảm đi.

(c) Tất cả các cây sẽ dự đoán cùng một kết quả cho mọi điểm dữ liệu.

(d) Thuật toán sẽ chạy nhanh hơn.

7. Giả sử trong bài toán thực hành, **Cây 1 (T_1)** được xây dựng trên mẫu bootstrap $\mathcal{D}_1 = \{1, 5, 2, 6, 5, 3\}$. Điểm dữ liệu nào sau đây thuộc tập Out-of-Bag (OOB) của cây T_1?

   (a) ID = 1.

   (b) ID = 3.

   (c) ID = 5.

   (d) ID = 4.

8. Xét mẫu bootstrap $\mathcal{D}_1$ trong bài thực hành. Nếu tại nút gốc, ta chỉ chọn ngẫu nhiên 2 đặc trưng là {**Chiều cao, Cân nặng**}, cách phân chia nào sẽ được chọn?

   (a) Chia theo "Chiều cao", vì Gini Gain lớn hơn.

   (b) Chia theo "Cân nặng", vì Gini Gain lớn hơn.

   (c) Cả hai cách chia đều cho Gini Gain bằng nhau.

   (d) Không thể chia vì Gini Gain của cả hai đều bằng 0.

9. Trong quá trình xây dựng Cây 2 (T_2), tại sao nút "Trung bình" (gồm hai mẫu {1, 6}) phải được phân chia tiếp?

   (a) Vì nút này có ít hơn 3 mẫu dữ liệu.

   (b) Vì Gini Impurity của nút này lớn hơn 0.

   (c) Vì nó nằm ở độ sâu bằng 1 của cây.

   (d) Vì đặc trưng "Chiều cao" là đặc trưng dạng phân loại.

10. Giả sử ta thay đổi mẫu kiểm tra trong bài thực hành thành **ID=8 (Đen, Cao, Nặng, Không)**. Kết quả dự đoán cuối cùng của mô hình Random Forest (gồm cả 3 cây T_1, T_2, T_3) là gì?

    (a) "Cháy nắng".

    (b) "Không".

    (c) Không xác định được do hòa phiếu.

    (d) Cả "Cháy nắng" và "Không".

Phụ lục

1. **Datasets:** Các file dataset được đề cập trong bài có thể được tải tại đây.
2. **Hint:** Các file code gợi ý có thể được tải tại đây.
3. **Demo:** Chương trình demo cho nội dung trong bài có thể được truy cập tại đây.
4. **Solution:** Các file code cài đặt hoàn chỉnh và phần trả lời nội dung trắc nghiệm có thể được tải tại đây.